EQUIPO 7

Generar y ordenar datos

RandomTextWriter, RandomWriter y Sort en Hadoop

Integrantes

Eli Garcia Perez

Juan Pedro Carapia Rocha

Jethro Ivann Valle Gomez

Introducción



Big Data

Generar, almacenar y organizar grandes cantidades de información es parte fundamental del procesamiento de datos.



Hadoop

Framework de código abierto que almacena y procesa grandes volúmenes de datos en computadoras conectadas entre sí.



Este trabajo

Explica tres programas de ejemplo de Hadoop: RandomTextWriter, RandomWriter y Sort, y su relación con MapReduce.

Objetivo



Conocer y comprender el funcionamiento de RandomTextWriter, RandomWriter y Sort, identificando sus diferencias, aplicaciones y cómo generan y ordenan información mediante procesamiento distribuido.

También: demostrar su funcionamiento dentro de un contenedor mediante la ejecución de comandos, generación de datos y consulta de resultados.

¿Qué hacen las herramientas?



RandomTextWriter

Genera archivos con texto aleatorio



RandomWriter

Genera registros clave-valor aleatorios



Sort

Ordena registros mediante MapReduce

RandomTextWriter



¿Qué es?

Programa de ejemplo de Hadoop que genera archivos con contenido de texto aleatorio.

Utilidad

Realizar pruebas de escritura y almacenamiento, para evaluar cómo responde el sistema al guardar grandes cantidades de información.

Ejemplo

Generar archivos de prueba y comprobar cuánto tiempo necesita Hadoop para almacenarlos.

RandomWriter



¿Qué es?

Genera registros aleatorios en forma de pares clave-valor, en formato binario de Hadoop (BytesWritable).

Utilidad

Generar datos sintéticos para probar el rendimiento de los procesos de escritura y procesamiento distribuido.

Ejemplo

Una empresa genera miles de registros artificiales para comprobar si su infraestructura soporta grandes volúmenes de información.

Sort



¿Qué es?

Programa de ejemplo de Hadoop que ordena datos mediante MapReduce. Recibe pares clave-valor y entrega los registros organizados por clave.

Utilidad

Comprobar la capacidad de Hadoop para ordenar grandes cantidades de información usando diferentes tareas de procesamiento.

Ejemplo

Tomar los registros generados con RandomWriter y obtener una salida ordenada por sus claves.

Diferencias entre las herramientas

Herramienta	Función principal	Tipo de información
RandomTextWriter	Generar texto aleatorio	Texto
RandomWriter	Generar pares clave-valor	Datos binarios
Sort	Ordenar registros	Pares clave-valor

Caso real de aplicación

Una empresa recopila con sensores temperatura, humedad y consumo eléctrico, y recibe millones de registros.



1. Problema

¿Puede la infraestructura almacenar y procesar millones de registros?



2. Generar

RandomTextWriter y RandomWriter crean información artificial, sin datos reales.



3. Ordenar

Sort mide cuánto tarda Hadoop en ordenar los registros generados.

En resumen

1. **RandomTextWriter** genera texto aleatorio para probar escritura y almacenamiento.
2. **RandomWriter** genera pares clave-valor binarios para probar el procesamiento distribuido.
3. **Sort** ordena registros por clave con MapReduce.

¡Gracias!